



KERJA PRAKTIK - EF234603

PENGEMBANGAN MODUL KOREKSI DAN KLASIFIKASI ARTEFAK CITRA OTAK SEBAGAI BAGIAN DARI SISTEM *FAULT TOLERANCE IMAGE CAPTIONING*

Laboratorium Manajemen Cerdas Informasi

Jalan Teknik Kimia - Gedung Departemen Teknik Informatika,
Kampus Institut Teknologi Sepuluh Nopember
Jalan Raya ITS, Sukolilo, Surabaya 60111, Indonesia

Periode: 27 Mei 2025 - 27 Agustus 2025

Oleh:

Alief Gilang Permana Putra 5025221193

Pembimbing Jurusan

Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D.

Pembimbing Lapangan

Dr. Kelly Rossa Sungkono, S.Kom., M.Kom.

DEPARTEMEN TEKNIK INFORMATIKA

**Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember
Surabaya 2025**



KERJA PRAKTIK - EF234603

PENGEMBANGAN MODUL KOREKSI DAN KLASIFIKASI ARTEFAK CITRA OTAK SEBAGAI BAGIAN DARI SISTEM *FAULT TOLERANCE IMAGE CAPTIONING*

Laboratorium Manajemen Cerdas Informasi

Jalan Teknik Kimia - Gedung Departemen Teknik Informatika,
Kampus Institut Teknologi Sepuluh Nopember
Jalan Raya ITS, Sukolilo, Surabaya 60111, Indonesia

Periode: 27 Mei 2025 - 27 Agustus 2025

Oleh:

Alief Gilang Permana Putra 5025221193

Pembimbing Jurusan

Shintami Chusnul Hidayati, S.Kom., M.Sc., Ph.D.

Pembimbing Lapangan

Dr. Kelly Rossa Sungkono, S.Kom., M.Kom.

**DEPARTEMEN TEKNIK INFORMATIKA
Fakultas Teknologi Elektro dan Informatika Cerdas
Institut Teknologi Sepuluh Nopember
Surabaya 2025**

Halaman ini sengaja dikosongkan

DAFTAR ISI

DAFTAR ISI	iv
DAFTAR GAMBAR	vii
DAFTAR TABEL	ix
DAFTAR KODE	xi
LEMBAR PENGESAHAN	xiii
KATA PENGANTAR	xvii
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Permasalahan	2
1.3 Tujuan	2
1.4 Manfaat	2
1.5 Waktu dan Tempat Pelaksanaan	3
1.6 Metodologi Kerja Praktik	3
1.7 Sistematika Penulisan	4
2 PROFIL PERUSAHAAN	7
2.1 Profil Laboratorium MCI	7
2.2 Lokasi Laboratorium MCI	8
2.3 Struktur Organisasi Laboratorium MCI	8
3 TINJAUAN PUSTAKA	9
3.1 <i>Magnetic Resonance Imaging</i>	9
3.2 Artefak MRI	9
3.3 <i>ResNet</i>	10

3.4	<i>DenseNet</i>	11
3.5	<i>EfficientNet</i>	12
3.6	<i>Vision Transformer (ViT)</i>	13
3.7	<i>Swin Transformer V2</i>	14
3.8	<i>Generative Adversarial Network</i>	15
3.9	<i>Pix2Pix</i>	15
3.10	Metrik Evaluasi	16
3.10.1	Metrik Evaluasi Klasifikasi Gambar	16
3.10.2	<i>Peak Signal-to-Noise Ratio (PSNR)</i>	17
3.10.3	<i>Structural Similarity Index Measure (SSIM)</i>	17
4	DESAIN DAN IMPLEMENTASI	19
4.1	Deskripsi Sistem	19
4.1.1	Desain Pembuatan Dataset Simulasi	19
4.1.2	Desain Modul Klasifikasi Artefak	20
4.1.3	Desain Modul Koreksi Citra	21
4.2	Implementasi Sistem	23
4.2.1	Implementasi Pembuatan Dataset	23
4.2.2	Implementasi Modul Klasifikasi	25
4.2.3	Implementasi Modul Koreksi Citra	28
5	PENGUJIAN DAN EVALUASI	35
5.1	Skenario Pengujian	35
5.1.1	Lingkungan Pengujian	35
5.1.2	Skenario Pengujian Modul Klasifikasi	35
5.1.3	Skenario Pengujian Modul Koreksi	37
5.2	Evaluasi Pengujian	37
5.2.1	Evaluasi Modul Klasifikasi Artefak	37
5.2.2	Evaluasi Modul Koreksi Citra	40
6	KESIMPULAN DAN SARAN	43
6.1	Kesimpulan	43
6.2	Saran	43

DAFTAR PUSTAKA	45
BIODATA PENULIS	53

DAFTAR GAMBAR

2.1	Logo Laboratorium MCI	7
2.2	Struktur Organisasi Laboratorium MCI	8
3.1	Gambaran Artefak pada MRI [20]	10
3.2	Mekanisme <i>Residual Learning</i> [1]	11
3.3	Arsitektur DenseNet [2]	12
3.4	Arsitektur <i>Vision Transformer</i> [3]	13
3.5	Arsitektur Swin Transformer V2 [4]	14
3.6	Struktur <i>Generative Adversarial Network</i>	15
4.1	Diagram Alur Pembuatan Dataset	20
4.2	Diagram Alur Modul Klasifikasi	21
4.3	Diagram Alur Modul Koreksi Citra	22
5.1	Kelas Klasifikasi Artefak pada Dataset	36
5.2	Grafik Akurasi Pelatihan Model CNN	38
5.3	<i>Confusion Matrix</i> Model Terbaik (SwinV2 Transformer)	39
5.4	Perbandingan Visual Hasil Koreksi Citra MRI	41

Halaman ini sengaja dikosongkan

DAFTAR TABEL

5.1	Konfigurasi <i>Hyperparameter</i> Model Klasifikasi	36
5.2	Perbandingan Kinerja Metrik Model Klasifikasi	38
5.3	Perbandingan Kinerja Metrik Model Koreksi GAN	40

Halaman ini sengaja dikosongkan

DAFTAR KODE

4.1	Fungsi Memuat dan Praproses Citra NIfTI	23
4.2	Fungsi <i>Image Corruption</i>	24
4.3	Implementasi Model CNN (ResNet, DenseNet, Efficient-Net)	25
4.4	Implementasi Model Transformer	27
4.5	Implementasi Generator U-Net	29
4.6	Implementasi <i>Discriminator</i> PatchGAN	30
4.7	Implementasi Fungsi <i>Loss Generator</i>	31
4.8	Implementasi <i>Train Step</i> GAN	32

Halaman ini sengaja dikosongkan

**LEMBAR PENGESAHAN
KERJA PRAKTIK**

**PENGEMBANGAN MODUL KOREKSI
DAN KLASIFIKASI ARTEFAK CITRA
OTAK SEBAGAI BAGIAN DARI
SISTEM *FAULT TOLERANCE IMAGE
CAPTIONING***

Oleh:

Alief Gilang Permana Putra

5025221193

Mengetahui,

Dosen Pembimbing
Kerja Praktik

Menyetujui,

Pembimbing Lapangan
Kerja Praktik

**Shintami Chusnul
Hidayati, S.Kom.,
M.Sc., Ph.D.**
NPP. 1987202012004

**Dr. Kelly Rossa
Sungkono, S.Kom.,
M.Kom.**
NIP. 1994201912088

Halaman ini sengaja dikosongkan

PENGEMBANGAN MODUL KOREKSI DAN KLASIFIKASI ARTEFAK CITRA OTAK SEBAGAI BAGIAN DARI SISTEM FAULT TOLERANCE IMAGE CAPTIONING

Nama Mahasiswa : Alief Gilang Permana Putra
NRP : 5025221193
Departemen : Teknik Informatika - FTEIC
Pembimbing Departemen : Shintami Chusnul Hidayati, S.Kom.,
M.Sc., Ph.D.
Pembimbing Lapangan : Dr. Kelly Rossa Sungkono, S.Kom.,
M.Kom

ABSTRAK

MRI (*Magnetic Resonance Imaging*) otak merupakan instrumen diagnostik krusial yang efektivitasnya sering terhambat oleh munculnya artefak gerak (*motion artifacts*) akibat durasi pemindaian yang lama. Artefak ini tidak hanya menurunkan kualitas visual bagi tenaga medis, tetapi juga secara signifikan mengurangi akurasi sistem kecerdasan buatan lanjutan seperti sistem *image captioning* medis. Kerja praktik ini bertujuan mengembangkan kerangka kerja *fault tolerance* yang terdiri dari modul klasifikasi untuk mendeteksi jenis artefak dan modul koreksi untuk memulihkan citra yang rusak. Metodologi penelitian ini mencakup simulasi artefak gerak berbasis manipulasi domain frekuensi (*k-space*) untuk pembentukan dataset, pengembangan model klasifikasi menggunakan berbagai arsitektur *deep learning*, serta implementasi modul koreksi citra. Pada modul klasifikasi, arsitektur SwinV2 Transformer memberikan performa terbaik dengan tingkat akurasi mencapai 93,82% dan F1-Score 95,36%, mengungguli model CNN konvensional dalam mengenali pola artefak yang kompleks. Sementara itu, modul koreksi yang menggunakan arsitektur Pix2Pix GAN mampu memulihkan integritas struktural dan ketajaman visual citra. Evaluasi kuantitatif menunjukkan peningkatan nilai SSIM dibandingkan citra berartefak yang menunjukkan keberhasilan rekonstruksi batas-batas anatomi otak, meskipun diiringi dengan *trade-off* pada nilai PSNR yang merefleksikan karakteristik model generatif dalam memprioritaskan kualitas secara persepsi dibandingkan akurasi piksel absolut. Secara keseluruhan,

integrasi kedua modul ini berhasil membentuk sistem mitigasi yang andal untuk memastikan citra yang diteruskan ke tahap analisis medis selanjutnya memiliki kualitas yang layak untuk tahap diagnosis.

Kata Kunci : MRI Otak, *Motion Artifact*, SwinV2 Transformer, Pix2Pix GAN, *Fault Tolerance*.

KATA PENGANTAR

Puji dan syukur ke hadirat Allah SWT atas segala rahmat, hidayah, dan karunia -Nya sehingga penulis dapat menyelesaikan salah satu kewajiban sebagai mahasiswa departemen teknik informatika, yaitu kerja praktik dengan judul "PENGEMBANGAN MODUL KOREKSI DAN KLASIFIKASI ARTEFAK CITRA OTAK SEBAGAI BAGIAN DARI SISTEM *FAULT TOLERANCE IMAGE CAPTIONING*" di Laboratorium Manajemen Cerdas Informasi.

Penulis menyadari masih banyak kekurangan baik dalam pelaksanaan kerja praktik maupun penyusunan buku laporan ini. Namun penulis berharap buku laporan ini dapat menjadi refleksi dan evaluasi bagi penulis serta dapat menambah wawasan pembaca dan menjadi sumber referensi.

Melalui buku ini, penulis mengucapkan terima kasih kepada orang-orang yang telah membantu dan memberikan dukungan dalam penyusunan laporan kerja praktik ini, baik secara langsung maupun tidak langsung kepada:

1. Kedua orang tua penulis.
2. Ibu Shintami Chusnul Hidayati, S.Kom, M.Sc., Ph.D, selaku dosen pembimbing kerja praktik.
3. Ibu Dr. Kelly Rossa Sungkono, S.Kom., M.Kom., selaku pembimbing lapangan kerja praktik.
4. Mas Ibad dan Mbak Sabrina, yang telah membantu dan membimbing penulis dalam melaksanakan kerja praktik.

Surabaya, Agustus 2025

Alief Gilang Permana Putra

Halaman ini sengaja dikosongkan

BAB I

PENDAHULUAN

1.1 Latar Belakang

Magnetic Resonance Imaging (MRI) merupakan salah satu teknologi pencitraan medis non invasif yang digunakan untuk melakukan visualisasi struktur otak secara detail dengan kemampuan yang dapat menghasilkan kontras jaringan lunak yang tinggi dan resolusi spasial yang baik [5]. Citra MRI otak digunakan secara luas dalam diagnosis, penelitian neurologi, dan pengembangan sistem berbasis *Artificial Intelligence* (AI) seperti deteksi, segmentasi, klasifikasi, dan *image captioning* [6]. MRI juga digunakan untuk menghasilkan citra dengan resolusi tinggi yang mendukung diagnosis penyakit otak seperti tumor dan stroke serta membantu dalam perencanaan terapi [7, 8].

Salah satu tantangan utama dalam akuisisi citra MRI adalah munculnya artefak terutama akibat pergerakan pasien selama proses pemindaian yang memakan waktu lama. Artefak ini dapat menurunkan kualitas citra, mengganggu analisis lanjutan, bahkan menyebabkan salah diagnosis atau perlunya pengulangan pemindaian [5]. Artefak juga berdampak signifikan pada akurasi diagnostik manusia maupun sistem berbasis AI [9]. Artefak pada MRI otak dapat diklasifikasikan berdasarkan sumber dan bentuknya. Salah satu jenis yang paling umum adalah *motion artifact*, yang dapat berupa translasi (gerakan vertikal/horizontal) dan rotasi kepala [10, 11]. Klasifikasi jenis dan tingkat keparahan artefak merupakan hal penting untuk menentukan strategi koreksi yang tepat [12].

Berbagai pendekatan telah dikembangkan untuk memperbaiki artefak pada citra MRI, mulai dari metode konvensional hingga *deep learning*. Model *deep learning* seperti U-Net, *stacked* U-Net, dan *deep residual network* telah terbukti efektif dalam mengurangi artefak gerak dan meningkatkan kualitas citra [13, 14]. *Generative Adversarial Networks* (GAN), termasuk Pix2Pix juga digunakan untuk melakukan perbaikan citra dengan melakukan translasi gambar dengan artefak menjadi gambar bebas artefak [5].

Kerja praktik ini mengusulkan pengembangan modul klasifikasi artefak gerak/*motion artifact* yang mampu membedakan jenis rotasi, translasi vertikal, dan translasi horizontal, serta modul koreksi artefak berbasis Pix2Pix GAN. Modul klasifikasi memanfaatkan arsitektur berbasis *neural network* seperti ResNet dan Transformer untuk mendeteksi dan mengklasifikasikan jenis artefak. Sementara itu, Pix2Pix GAN digunakan pada modul koreksi untuk memperbaiki citra MRI yang terdistorsi akibat artefak gerak. Pendekatan ini diharapkan dapat meningkatkan *robustness* sistem *image captioning* terhadap artefak citra MRI, sehingga mendukung sistem *fault tolerance image captioning* secara menyeluruh.

1.2 Rumusan Permasalahan

Berdasarkan latar belakang yang dipaparkan, berikut adalah rumusan masalah:

1. Bagaimana melakukan simulasi artefak translasi dan rotasi pada citra otak?
2. Bagaimana cara mengembangkan model berbasis *neural network* untuk klasifikasi artefak translasi dan rotasi pada citra otak?
3. Bagaimana cara melakukan koreksi artefak translasi dan rotasi pada citra otak menggunakan *Generative Adversarial Network* (GAN)?

1.3 Tujuan

Berikut adalah tujuan dari kerja praktik:

1. Melakukan simulasi artefak translasi dan rotasi pada citra otak.
2. Mengembangkan model berbasis *neural network* untuk klasifikasi artefak translasi dan rotasi pada citra otak.
3. Melakukan koreksi artefak translasi dan rotasi pada citra otak menggunakan *Generative Adversarial Network* (GAN).

1.4 Manfaat

Penelitian dan pengembangan modul dalam kerja praktik ini diharapkan dapat memberikan manfaat yang signifikan, baik bagi pengembangan ilmu pengetahuan maupun implementasi praktis di bidang medis. Berikut adalah manfaat dari kerja praktik:

1. Memberikan studi komparatif mendalam tentang efektivitas berbagai arsitektur *neural network* dan Transformer dalam tugas klasifi-

- kasi artefak gerak.
2. Mengevaluasi potensi dan performa arsitektur Pix2Pix GAN untuk tugas restorasi citra medis yang spesifik.
 3. Menghasilkan purwarupa modul *Quality Control* (QC) otomatis yang dapat mendeteksi citra MRI berkualitas buruk secara dini.
 4. Menyediakan komponen dasar untuk sistem *fault tolerance* guna meningkatkan keandalan sistem AI medis tingkat lanjut seperti *image captioning*.

1.5 Waktu dan Tempat Pelaksanaan

Kerja praktik ini dilaksanakan pada 27 Mei 2025 hingga 27 Agustus 2025 dan dikerjakan secara *remote*.

1.6 Metodologi Kerja Praktik

Metodologi dalam pembuatan buku kerja praktik ini meliputi:

1. Perumusan Masalah

Pada tahap ini, dilakukan identifikasi mendalam mengenai isu utama yang dihadapi, yaitu penurunan kualitas citra MRI akibat artefak gerak serta dampak negatif terhadap kinerja sistem *image captioning* medis. Perumusan masalah ini bertujuan untuk mendefinisikan secara jelas ruang lingkup permasalahan yang akan diselesaikan melalui pengembangan modul klasifikasi dan koreksi citra.

2. Studi Literatur

Tahap studi literatur dilakukan dengan mengkaji berbagai referensi ilmiah untuk memahami prinsip dasar fisika MRI dan karakteristik artefak gerak. Kajian ini juga mencakup eksplorasi arsitektur *deep learning* terkini yang relevan dengan tujuan penelitian, seperti Convolutional Neural Network (CNN), Transformer, dan Generative Adversarial Network (GAN) untuk menentukan metode yang paling tepat untuk diterapkan.

3. Analisis dan Perancangan Sistem

Tahap berikutnya adalah analisis dan perancangan sistem, yang dimulai dengan menganalisis karakteristik dataset BraTS dan menentukan kebutuhan praproses data yang diperlukan. Pada tahap ini, dirancang algoritma simulasi artefak yang berbasis pada manipulasi domain frekuensi (*k-space*) untuk menghasilkan data latih yang realistis. Simulasi artefak dilakukan karena kurangnya sumber data

artefak rill, dengan menggunakan parameter sesuai dengan skenario klinis asli yang didapatkan dari studi literatur. Selain itu, arsitektur model klasifikasi dirancang dengan memanfaatkan strategi *transfer learning*, sedangkan model koreksi dirancang menggunakan arsitektur GAN Pix2Pix untuk restorasi citra.

4. Implementasi Sistem

Setelah perancangan selesai, dilakukan implementasi sistem. Modul pra-pemrosesan dan simulasi artefak diimplementasikan menggunakan bahasa pemrograman Python. Proses pelatihan kemudian dilakukan untuk model-model klasifikasi, yaitu ResNet50, DenseNet121, EfficientNetB0, ViT, dan SwinV2 menggunakan dataset yang telah disimulasikan. Selain itu, model koreksi Pix2Pix GAN dilatih untuk mempelajari pemetaan dari citra dengan artefak menjadi citra bersih, sehingga mampu memperbaiki kualitas citra yang terdegradasi.

5. Pengujian dan Evaluasi

Tahap terakhir adalah pengujian dan evaluasi untuk mengukur kinerja sistem yang telah dibangun. Model klasifikasi diuji menggunakan metrik evaluasi standar seperti Akurasi, Presisi, *Recall*, dan *F1-Score* pada data uji yang terpisah. Sementara itu, efektivitas model koreksi dievaluasi secara kuantitatif menggunakan *Peak Signal-to-Noise Ratio* (PSNR) dan *Structural Similarity Index* (SSIM), serta dilakukan inspeksi visual untuk menilai kualitas hasil rekonstruksi citra secara kualitatif.

1.7 Sistematika Penulisan

Laporan kerja praktik akan terbagi menjadi 6 bagian, yaitu:

1. Bab I Pendahuluan

Bab ini memaparkan latar belakang masalah, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, metodologi yang digunakan, serta sistematika penulisan laporan.

2. Bab II Profil Perusahaan

Bab ini berisi gambaran umum Laboratorium Manajemen Cerdas Informasi (MCI) mulai dari profil dan lokasi perusahaan.

3. Bab III Tinjauan Pustaka

Bab ini membahas landasan teori yang relevan, mencakup prinsip dasar citra MRI, artefak gerak, serta tinjauan mendalam mengenai

arsitektur *neural network* dan GAN yang digunakan dalam penelitian.

4. **Bab IV Desain dan Implementasi**

Bab ini menjelaskan secara rinci desain sistem dan langkah-langkah implementasi. Pembahasan meliputi alur kerja simulasi data artefak, arsitektur model klasifikasi dan koreksi yang dibangun, serta konfigurasi pelatihan yang diterapkan.

5. **Bab V Pengujian dan Evaluasi**

Bab ini menyajikan hasil eksperimen dan pengujian sistem. Analisis mengenai perbandingan performa antar model klasifikasi serta evaluasi kualitas citra hasil koreksi GAN, baik secara visual maupun metrik kuantitatif dijelaskan secara rinci pada bagian ini.

6. **Bab VI Kesimpulan dan Saran**

Bab ini berisi kesimpulan dari seluruh rangkaian kerja praktik serta saran-saran untuk pengembangan sistem lebih lanjut di masa depan.

Halaman ini sengaja dikosongkan

BAB II

PROFIL PERUSAHAAN

2.1 Profil Laboratorium MCI



Gambar 2.1: Logo Laboratorium MCI


Laboratorium Manajemen Cerdas Informasi (MCI) menawarkan bidang keahlian yang ditekankan pada kemampuan lulusan dalam menganalisis, mensintesa dan mengevaluasi proses bisnis dan sistem informasi pada sistem Enterprise, mengimplementasikan rekayasa pengetahuan ke dalam suatu aplikasi, melakukan investigasi, pengujian, evaluasi kemandirian dan kepatutan terhadap prosedur standar dan tata kelola teknologi informasi, melakukan tata kelola proyek dan sumber daya manusia dan merancang dan mengimplementasikan solusi basis data terdistribusi dan teknologi *Big Data*. Mata kuliah bidang keahlian dibawah naungan MCI antara lain, Sistem Enterprise, Rekayasa Pengetahuan, Sistem Informasi Geografis, Audit Sistem, Tata Kelola Teknologi Informasi, Basis Data Terdistribusi, Big Data, Topik Khusus Manajemen Informasi.

2.2 Lokasi Laboratorium MCI

Laboratorium MCI berlokasi di Jalan Teknik Kimia - Gedung Departemen Teknik Informatika, Kampus Institut Teknologi Sepuluh Nopember Jalan Raya ITS, Sukolilo, Surabaya 60111, Indonesia.

2.3 Struktur Organisasi Laboratorium MCI

Laboratorium MCI dipimpin oleh ketua laboratorium dan terdiri dosen anggota. Gambar 2.2 menunjukkan struktur organisasi laboratorium MCI.



Gambar 2.2: Struktur Organisasi Laboratorium MCI

BAB III

TINJAUAN PUSTAKA


3.1 *Magnetic Resonance Imaging*

Magnetic Resonance Imaging (MRI) adalah teknik pencitraan medis non-invasif yang menghasilkan gambar dengan resolusi tinggi dan kontras jaringan lunak yang sangat baik, memungkinkan visualisasi struktur internal tubuh secara detail dalam format tiga dimensi. Dalam lima tahun terakhir, perkembangan signifikan terjadi pada sistem *low-field* MRI yang kini mampu memberikan performa klinis mendekati *high-field* MRI, dengan keunggulan seperti biaya lebih rendah dan keamanan yang lebih baik untuk pasien tertentu [15, 16]. Selain itu, real-time MRI (RT-MRI) memungkinkan pencitraan proses dinamis secara langsung tanpa perlu pengulangan, sangat berguna untuk organ yang bergerak seperti jantung dan saluran pencernaan, serta dalam panduan prosedur intervensional [17]. Dengan kemajuan teknologi ini, MRI menjadi alat diagnostik yang esensial dalam berbagai bidang medis, termasuk neurologi, kardiologi, dan onkologi, dengan kemampuan yang terus ditingkatkan untuk menghasilkan citra berkualitas tinggi dan informasi fungsional yang mendalam [15, 17, 18]

3.2 Artefak MRI

Artefak dalam pencitraan MRI merupakan masalah yang timbul karena akuisisi citra yang lambat dan sekuensial, dimana data dikumpulkan pada k -ruang (k -space) [19]. Dalam pencitraan otak, artefak gerak (*motion artifacts*) adalah jenis degradasi citra yang paling sering ditemui [14]. Artefak ini timbul dari gerakan pasien, baik secara sengaja maupun tidak disengaja karena proses yang dibutuhkan untuk mengumpulkan data citra cukup lama [13]. Gerakan ini umumnya dikategorikan sebagai *rigid body motion* yang meliputi translasi horizontal, translasi vertikal, dan rotasi. Translasi menyebabkan terjadinya pergeseran fase atau *phase ramp* pada data k -space yang dikumpulkan. Sementara itu, rotasi menyebabkan perubahan orientasi pada k -space ketika komponen frekuensi spasial objek berputar terhadap gradien *encoding*. Hal ini mengakibatkan kepadatan

(*density*) pengambilan sampel di beberapa area *k-space* jatuh di bawah batas Nyquist yang memicu munculnya artefak berupa garis-garis (*streaking*) [20].




Gambar 3.1: Gambaran Artefak pada MRI [20]

Secara visual, artefak gerakan biasanya tampak sebagai *blur* atau bayangan (*ghosting*) pada *phase encoding direction*, yang dapat menurunkan kualitas citra hingga tidak dapat digunakan untuk diagnosis [19]. Bahkan, artefak gerakan dapat memengaruhi 10% hingga 42% pemeriksaan MRI otak, dan dapat menimbulkan bias sistematis dalam perkiraan morfometrik struktur otak [10, 14].

3.3 ResNet

ResNet (*Residual Network*) adalah arsitektur *deep neural network* yang dirancang untuk mengatasi masalah degradasi performa pada *deep network* dengan menggunakan mekanisme *residual learning* melalui *shortcut connections* yang melakukan pemetaan identitas dan menambahkan *output* tersebut pada *stacked layers* [1].




Gambar 3.2: Mekanisme *Residual Learning* [1]

Arsitektur ini telah menjadi dasar bagi banyak varian dan pengembangan, seperti Res2Net yang memperkenalkan koneksi residual hierarkis dalam satu blok residual untuk meningkatkan representasi fitur *multiscale*, sehingga meningkatkan kinerja pada berbagai tugas visi komputer [21]. Dalam bidang pengolahan citra medis, ResNet telah banyak digunakan untuk diagnosis berbagai penyakit seperti tumor paru, kanker payudara, dan gangguan otak, dengan kemampuan adaptasi yang baik terhadap data medis dan memberikan hasil yang baik dalam diagnosis dengan bantuan komputer [22].

3.4 *DenseNet*

DenseNet adalah arsitektur *convolutional neural network* yang menghubungkan setiap lapisan secara langsung dengan semua lapisan sebelumnya sehingga meningkatkan efisiensi pemanfaatan fitur dan mengatasi masalah *vanishing gradient*.



Gambar 3.3: Arsitektur DenseNet [2]

Dalam bidang medis, DenseNet telah banyak diterapkan untuk segmentasi dan klasifikasi citra medis dengan hasil yang baik. DRINet menggabungkan blok konvolusi dengan koneksi *dense* dan modul *residual inception* untuk segmentasi multi kelas pada citra CT dan MRI otak, menunjukkan performa lebih baik dibandingkan U-Net tradisional [23]. DenseNet juga digunakan dalam klasifikasi citra histopatologi kanker payudara dengan melakukan *interleaving* modul *squeeze-and-excitation* (SENet) yang meningkatkan akurasi klasifikasi dibandingkan metode lain [24]. Selain itu, model ringan yang menggabungkan PCANet dan DenseNet berhasil meningkatkan klasifikasi citra mamografi dan histologi osteosarkoma dengan pelatihan yang lebih efisien pada dataset kecil [25]. Strategi *fine-tuning* DenseNet pada berbagai modalitas citra medis juga menunjukkan peningkatan performa signifikan yang menunjukkan fleksibilitas dan keunggulan DenseNet dalam aplikasi medis [26].


3.5 EfficientNet

EfficientNet adalah arsitektur CNN yang mengoptimalkan keseimbangan antara kedalaman, lebar, dan resolusi jaringan menggunakan metode *compound scaling* sehingga menghasilkan model yang efisien dengan jumlah parameter relatif kecil namun tetap memiliki kinerja tinggi [27]. Dalam aplikasi medis, EfficientNet banyak digunakan untuk klasifikasi dan diagnosis penyakit dengan akurasi yang baik. Sebagai contoh, Deep-

EFNet yang berbasis EfficientNetB0 dapat mengklasifikasikan tumor otak pada citra MRI dengan akurasi hingga 98% dengan performa stabil di berbagai dataset melalui penambahan *batch normalization*, *dropout*, dan regularisasi L2 [28]. Pada klasifikasi kanker payudara, kombinasi EfficientNetB0 dan ResNet50 meningkatkan akurasi hingga 94%, menunjukkan keunggulan arsitektur ini dalam mendeteksi kanker histopatologi [29]. Selain itu, EfficientNet juga digunakan dalam model klasifikasi citra medis lain dengan efisiensi komputasi yang baik sehingga menjadi pilihan populer untuk aplikasi medis yang membutuhkan keseimbangan antara akurasi dan kecepatan pemrosesan [30].

3.6 Vision Transformer (ViT)

Vision Transformer (ViT) memodelkan citra sebagai urutan *patch* dan menggunakan *self-attention* untuk menangkap dependensi jarak jauh serta konteks global, sehingga melengkapi CNN yang hanya memiliki *receptive field lokal* [31]. Secara umum, ViT memperlakukan citra dua dimensi sebagai urutan token (*patch citra*) dan memprosesnya dengan encoder Transformer standar sehingga struktur dasarnya mirip dengan Transformer untuk NLP yang ditambahkan tahap tokenisasi citra dan penambahan positional embedding [32].




Gambar 3.4: Arsitektur *Vision Transformer* [3]

Dalam bidang medis, ViT banyak dipakai untuk klasifikasi, segmentasi, deteksi, registrasi, dan rekonstruksi, serta seringkali digabungkan dengan CNN dalam arsitektur hibrida agar fitur lokal dan global dapat di-

ekstraksi secara bersamaan [33, 34]. Berbagai studi dan tinjauan menunjukkan bahwa model berbasis transformer ini umumnya melampaui atau setidaknya menyaingi CNN/U-Net konvensional pada tugas segmentasi organ dan tumor, klasifikasi tumor otak, kanker payudara histopatologi, dan diagnosis retina [35, 36].

3.7 Swin Transformer V2

Swin Transformer V2 (SwinV2) adalah pengembangan dari Swin Transformer yang menggunakan mekanisme *self-attention* dalam jendela geser untuk menangkap dependensi lokal dan global secara efisien dengan kompleksitas komputasi rendah. Model ini menggabungkan konvolusi dan *self-attention* melalui struktur seperti Swin Transformer *Stem* dan *dual-branch downsampling* untuk meningkatkan ekstraksi fitur, serta menggunakan teknik stabilisasi pelatihan seperti *residual post normalization* dan *scaled cosine attention* agar dapat dilatih pada resolusi tinggi dan model besar hingga 3 miliar parameter [4].




Gambar 3.5: Arsitektur Swin Transformer V2 [4]

SwinV2 telah diterapkan dalam berbagai bidang, termasuk segmentasi polip usus dengan model hibrida CNN-Transformer yang menunjukkan performa unggul pada dataset benchmark, serta segmentasi 3D medis dengan SwinUNETR-V2 yang menggabungkan konvolusi bertahap untuk

hasil lebih baik [37, 38]. Pendekatan hierarkis dan *shifted windows* membuat SwinV2 mampu mengoptimalkan efisiensi dan efektivitas pemodelan konteks spasial pada citra kompleks [4]. Dengan peningkatan stabilitas, skalabilitas, dan kemampuan generalisasi, SwinV2 menjadi model kuat untuk pengolahan citra dan aplikasi medis

3.8 Generative Adversarial Network

Generative Adversarial Networks (GAN) adalah model generatif yang terdiri dari dua jaringan, yaitu *generator* dan *discriminator* yang dilatih secara kompetitif untuk menghasilkan data baru yang realistis dari distribusi data asli [39].



Gambar 3.6: Struktur *Generative Adversarial Network*

GAN banyak digunakan dalam bidang medis, terutama untuk pengolahan citra medis seperti fusi citra, augmentasi data, segmentasi, dan rekonstruksi gambar. GAN mampu menghasilkan citra medis sintetis yang realistis, membantu mengatasi keterbatasan data pelatihan dan ketidakseimbangan kelas pada dataset medis [40, 41]. Berbagai varian GAN seperti cGAN dan DCGAN sering dipakai untuk meningkatkan kualitas dan kuantitas data medis pada modalitas seperti MRI, CT, dan X-ray, serta organ seperti otak, dada, dan payudara [42]. Selain itu, GAN juga digunakan untuk deteksi penyakit, klasifikasi, dan peningkatan resolusi citra medis, yang mendukung diagnosis dan pelatihan klinis [43, 44].

3.9 Pix2Pix

Pix2Pix adalah model *image-to-image translation* berbasis *conditional* GAN yang mampu mempelajari pemetaan dari gambar input ke gam-

bar output dengan fungsi *loss* yang dipelajari secara otomatis, sehingga dapat diaplikasikan pada berbagai tugas seperti rekonstruksi objek, pewarnaan gambar, dan sintesis foto dari peta label [45]. Dalam bidang medis, Pix2Pix digunakan untuk augmentasi data dan peningkatan kualitas citra seperti menghasilkan citra tomografi kornea yang realistis untuk membantu klasifikasi penyakit seperti *keratoconus* untuk meningkatkan kinerja model klasifikasi dibandingkan dengan hanya menggunakan data asli saja [46]. Varian Pix2Pix juga diterapkan untuk menghasilkan citra tumor dari *free sketch* guna mendukung augmentasi data pada diagnosis kanker paru-paru [47]. Secara keseluruhan, Pix2Pix merupakan metode yang efektif dan fleksibel untuk transformasi citra yang banyak dimanfaatkan dalam pengolahan citra medis dan augmentasi data.

3.10 Metrik Evaluasi

Pada bagian ini, dijelaskan metrik evaluasi yang digunakan untuk mengukur kinerja model klasifikasi dan model koreksi. Evaluasi dilakukan untuk menilai seberapa akurat hasil klasifikasi artefak dan koreksi citra dibandingkan dengan label dan gambar yang asli.

3.10.1 Metrik Evaluasi Klasifikasi Gambar

Metrik evaluasi klasifikasi gambar digunakan untuk menilai kinerja model dalam mengklasifikasikan data gambar *Confusion matrix* adalah matrix yang menunjukkan jumlah prediksi benar dan salah yang dibagi ke dalam empat kategori: *True Positive* (TP), *False Positive* (FP), *True Negative* (TN), dan *False Negative* (FN) [48]. Dari *confusion matrix*, dapat dihitung beberapa metrik utama:

1. Akurasi mengukur proporsi prediksi yang benar dari seluruh data yang dihitung menggunakan Persamaan 3.1.

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.1)$$

2. Presisi menunjukkan seberapa tepat prediksi positif, dihitung dengan Persamaan 3.2.

$$Presisi = \frac{TP}{TP + FP} \quad (3.2)$$

3. *Recall* atau sensitivitas mengukur kemampuan model menemukan semua kasus positif yang dihitung dengan Persamaan 3.3.

$$Recall = \frac{TP}{TP + FN} \quad (3.3)$$

4. *F1-Score* adalah rata-rata harmonis dari presisi dan *recall* yang memberikan keseimbangan antara kedua metrik tersebut yang dihitung dengan Persamaan 3.4.

$$F1-Score = 2 \times \frac{Presisi \times Recall}{Presisi + Recall} \quad (3.4)$$

Metrik-metrik ini sangat berguna terutama pada dataset yang tidak seimbang, karena dengan menggunakan akurasi saja dapat menyesatkan jika kelas dominan sangat banyak [49]. Penggunaan *confusion matrix* dan metrik klasifikasi ini membantu dalam memahami kekuatan dan kelemahan model klasifikasi gambar secara lebih mendalam [50].

3.10.2 Peak Signal-to-Noise Ratio (PSNR)

Peak Signal-to-Noise Ratio (PSNR) adalah metrik yang digunakan untuk mengukur kualitas citra hasil pemrosesan dengan membandingkan citra hasil dengan citra referensi asli. PSNR mengukur rasio antara nilai puncak sinyal dengan tingkat *noise* yang mengganggu sinyal tersebut dan biasanya dinyatakan dalam satuan desibel (dB) [51]. Semakin tinggi nilai PSNR, semakin baik kualitas citra hasil karena tingkat *noise* yang lebih rendah, sehingga hasil citra lebih mendekati citra asli [52]. PSNR menjadi metrik dasar yang penting dalam evaluasi kualitas citra, khususnya dalam konteks kompresi, denoising, dan rekonstruksi citra [51].

3.10.3 Structural Similarity Index Measure (SSIM)

Structural Similarity Index Measure (SSIM) adalah metrik yang digunakan untuk menilai kualitas citra dengan mengukur kesamaan struktural antara citra asli dan citra hasil pemrosesan. SSIM mempertimbangkan tiga aspek utama yaitu luminansi, kontras, dan struktur, sehingga lebih mencerminkan persepsi visual manusia dibandingkan metrik tradisional seperti MSE atau PSNR [51, 53]. SSIM sangat populer dalam berbagai aplikasi pengolahan citra dan computer vision karena kemampuannya untuk menangkap perubahan visual yang penting secara struktural [54]. SSIM juga

dapat digunakan untuk evaluasi kualitas citra medis, pengenalan pola, dan verifikasi tanda tangan digital [53, 55]. Secara umum, SSIM memberikan pengukuran kualitas citra yang lebih sesuai dengan persepsi manusia dibandingkan metrik berbasis *error* absolut.

BAB IV

DESAIN DAN IMPLEMENTASI


4.1 Deskripsi Sistem

Sistem yang dikembangkan dalam kerja praktik ini adalah sebuah kerangka kerja *fault tolerance* untuk pemrosesan citra medis, khususnya MRI otak. Sistem ini dirancang untuk melakukan mitigasi dampak negatif dari artefak gerak (*motion artifacts*) sebelum citra diproses lebih lanjut oleh sistem lanjutan *image captioning*. Secara garis besar, sistem terdiri dari tiga komponen utama yang saling terintegrasi:

1. **Modul simulasi data** yang bertugas untuk menghasilkan dataset sintetis untuk menyimulasikan artefak gerak yang terjadi di dunia nyata.
2. **Modul klasifikasi artefak** yang bertugas mendeteksi jenis artefak gerak dengan empat kelas klasifikasi yaitu translasi horizontal, translasi vertikal, rotasi, dan gambar bersih pada citra.
3. **Modul koreksi citra** yang bertugas merekonstruksi citra dengan artefak menjadi citra bersih.

4.1.1 Desain Pembuatan Dataset Simulasi

Untuk melatih model koreksi citra dengan Pix2Pix, diperlukan pasangan data citra bersih dan artefak. Dataset asli yang digunakan dalam penelitian ini bersumber dari dataset BraTS (*Brain Tumor Segmentation*) yang merupakan kumpulan citra MRI otak dalam format tiga dimensi (3D). Mengingat fokus utama pengembangan sistem saat ini adalah pemrosesan pada citra dua dimensi (2D), dilakukan proses ekstraksi pada *slice* tengah dari setiap volume 3D untuk dijadikan representasi data yang akan diolah. Pemilihan irisan tengah ini bertujuan untuk mendapatkan luas penampang otak yang paling informatif untuk mempermudah model dalam mempelajari fitur anatomi yang kompleks. Sistem ini menggunakan pendekatan simulasi berbasis domain frekuensi (*k-space*) untuk melakukan simulasi artefak gerak sesuai dengan kondisi pada dunia nyata. Proses pembuatan dataset latih ditunjukkan pada Gambar 4.1.



Gambar 4.1: Diagram Alur Pembuatan Dataset


Secara umum, proses simulasi artefak terdiri dari tiga bagian, yaitu:

1. Transformasi citra bersih ke k -space domain frekuensi menggunakan *Fast Fourier Transform* (FFT).
2. Simulasi artefak dengan menggabungkan (*splicing*) garis-garis frekuensi dari citra diam dengan citra yang telah dimanipulasi secara geometris. Pada tahap ini, parameter pergeseran untuk translasi ditetapkan antara 5 hingga 20 piksel, sedangkan untuk rotasi ditetapkan antara 3 hingga 15 derajat. Proses ini meniru inkonsistensi fase yang terjadi ketika pasien bergerak selama pemindaian MRI.
3. Rekonstruksi citra dari data *corrupt k-space* dikembalikan ke domain spasial menggunakan *Inverse FFT* untuk menghasilkan artefak *ghosting* dan *streaking* yang realistis.

4.1.2 Desain Modul Klasifikasi Artefak

Modul klasifikasi dirancang menggunakan pendekatan *Transfer Learning* dari model *pre-trained* untuk mengklasifikasikan empat kelas artefak citra, yaitu bersih, *horizontal translation*, *vertical translation*, dan

rotasi. Proses klasifikasi secara detail dapat dilihat pada Gambar 4.2.




Gambar 4.2: Diagram Alur Modul Klasifikasi

Desain modul klasifikasi ini mengeksplorasi dua arsitektur *deep learning* untuk tugas *computer vision*, yaitu *Convolutional Neural Network* (CNN) menggunakan model ResNet, DenseNet, dan EfficientNet serta arsitektur Transformer menggunakan *Vision Transformer* (ViT) dan Swin Transformer. Lapisan akhir setiap model dimodifikasi menjadi *classification head* untuk menghasilkan probabilitas bagi empat kelas target.

4.1.3 Desain Modul Koreksi Citra

Modul koreksi dirancang untuk tugas translasi gambar ke gambar (*image-to-image translation*). Arsitektur yang digunakan adalah Pix2Pix *Conditional GAN* untuk merekonstruksi gambar bersih dari gambar dengan artefak. Arsitektur modul koreksi dapat dilihat pada Gambar 4.3.



Gambar 4.3: Diagram Alur Modul Koreksi Citra

Pix2Pix terdiri dari dua komponen yang saling berkompetisi:

1. *Generator* berbasis U-Net yang bertugas menerima input citra dengan artefak dan menghasilkan citra bersih. Arsitektur U-Net digunakan karena adanya *skip connections* yang memungkinkan informasi detail struktur otak dari input tetap terjaga hingga *output*.
2. *Discriminator* berbasis *convolutional PatchGAN* yang bertugas membedakan antara citra bersih asli dan citra hasil rekonstruksi *Generator*. PatchGAN bekerja dengan menilai realisme citra pada level *patch* lokal yang efektif untuk menghasilkan tekstur yang tajam.

4.2 Implementasi Sistem

Implementasi sistem dilakukan menggunakan bahasa pemrograman Python di lingkungan *notebook* interaktif pada Kaggle. *Library* utama yang digunakan meliputi TensorFlow/Keras untuk model CNN dan GAN, PyTorch dan Hugging Face Transformers untuk model Transformer, serta NumPy dan SciPy untuk simulasi dan manipulasi citra.

4.2.1 Implementasi Pembuatan Dataset

Tahap ini bertujuan untuk menciptakan dataset pelatihan sintetis yang merepresentasikan *motion artefacts* secara realistis. Tahap ini terdiri dari beberapa bagian:

A. Praproses Citra

Proses ini diimplementasikan pada fungsi `load_and_resize_nifti` yang dapat dilihat pada Kode 4.1.

```
1 def load_and_resize_nifti(nifti_path):
2     try:
3         img_nii = nib.load(nifti_path)
4         img_data = img_nii.get_fdata()
5
6         # Ambil slice tengah
7         slice_idx = img_data.shape[2] // 2
8         slice_2d = img_data[:, :, slice_idx]
9         slice_2d = np.nan_to_num(slice_2d)
10
11        # Normalisasi ke range [0, 255]
12        if slice_2d.max() > slice_2d.min():
13            slice_2d = (slice_2d - slice_2d.min()) / (↵
14                slice_2d.max() - slice_2d.min()) * 255.0
15
16        # Konversi ke uint8 sebelum resizing ke PIL
17        slice_2d_uint8 = slice_2d.astype(np.uint8)
18        pil_img = Image.fromarray(slice_2d_uint8)
19        pil_img = pil_img.resize((IMG_WIDTH, IMG_HEIGHT), ↵
20            Image.NEAREST)
21        return np.array(pil_img).astype(np.float32)
22    except (nib.filebasedimages.ImageFileError, ↵
23        FileNotFoundError):
24        return None
```

Kode 4.1: Fungsi Memuat dan Praproses Citra NIFTI

Pada Kode 4.1, citra MRI format NIfTI 3D dimuat, kemudian *slice* tengah diekstraksi dan dinormalisasi. Fungsi ini juga mengubah ukuran citra ke dimensi standar 256×256 piksel.

B. Simulasi Artefak

Inti dari simulasi citra MRI terdapat pada fungsi `apply_kspace_corruption` yang ditunjukkan pada Kode 4.2.

```
1 def apply_kspace_corruption(clean_image_2d, ↵
    moved_image_2d, corruption_percent):
2
3     # 1. Konversi ke K-Space (FFT)
4     kspace_clean = np.fft.fft2(clean_image_2d.astype(np.↵
        complex64))
5     kspace_moved = np.fft.fft2(moved_image_2d.astype(np.↵
        complex64))
6
7     # 2. Buat corrupted k-space
8     height, width = clean_image_2d.shape
9
10    corruption_lines = int(height * corruption_percent)
11    if corruption_lines >= height:
12        corruption_lines = height - 1
13    if corruption_lines <= 0:
14        corruption_lines = 1
15
16    start_line = np.random.randint(0, height - ↵
        corruption_lines)
17    end_line = start_line + corruption_lines
18
19    mask_line = np.concatenate([
20        np.ones(start_line, dtype=bool),
21        np.zeros(corruption_lines, dtype=bool),
22        np.ones(height - end_line, dtype=bool)
23    ], axis=0)
24    mask = np.tile(mask_line[:, np.newaxis], [1, width])
25
26    kspace_corrupted = np.where(mask, kspace_clean, ↵
        kspace_moved)
27
28    # 3. Konversi balik ke gambar (IFFT)
29    corrupted_image_complex = np.fft.ifft2(↵
        kspace_corrupted)
30    corrupted_image_abs = np.abs(corrupted_image_complex)↵
        .astype(np.float32)
31
```

```

32  # 4. Normalisasi ke 0-255 uint8 untuk disimpan ↵
      sebagai gambar PIL
33  if corrupted_image_abs.max() > corrupted_image_abs.↵
      min():
34      corrupted_image_abs = (corrupted_image_abs - ↵
          corrupted_image_abs.min()) / (↵
          corrupted_image_abs.max() - corrupted_image_abs↵
          .min()) * 255.0
35
36  # 5. Tumpuk 3 channel untuk konsistensi
37  return np.stack([corrupted_image_abs] * 3, axis=-1).↵
      astype(np.uint8)

```

Kode 4.2: Fungsi *Image Corruption*

Fungsi ini menerima citra asli dan citra yang telah dirotasi atau di-translasi. Kedua citra dikonversi ke domain frekuensi (*k-space*) menggunakan FFT. Kemudian, sebagian garis frekuensi citra asli diganti dengan garis frekuensi dari citra yang digerakkan untuk mensimulasikan inkonsistensi data saat pasien bergerak.

4.2.2 Implementasi Modul Klasifikasi

Modul klasifikasi merupakan komponen yang bertugas mengklasifikasi citra MRI ke dalam empat kategori, yaitu *Clean*, *Rotation Artifact*, *Vertical Translation*, dan *Horizontal Translation*. Implementasi modul ini dilakukan menggunakan dua pendekatan arsitektur model *pretrained*, yaitu *Convolutional Neural Network* dan *Transformer* untuk membandingkan efektivitas dalam mendeteksi pola artefak.

A. Implementasi Model CNN

Implementasi model CNN dilakukan menggunakan *library* TensorFlow dan Keras dengan strategi *transfer learning* yang ditunjukkan pada Kode 4.3.

```

1  def build_cnn_model(model_name, input_shape, ↵
      num_classes):
2
3      # Inisialisasi base model
4      if model_name == 'ResNet50':
5          base_model = ResNet50(input_shape=input_shape, ↵
              include_top=False, weights='imagenet')
6      elif model_name == 'DenseNet121':
7          base_model = DenseNet121(input_shape=input_shape, ↵

```

```

        include_top=False, weights='imagenet')
8 elif model_name == 'EfficientNetB0':
9     base_model = EfficientNetB0(input_shape=input_shape↵
        , include_top=False, weights='imagenet')
10
11 # Bekukan base mode
12 base_model.trainable = False
13
14 # Buat classifier head baru
15 inputs = layers.Input(shape=input_shape)
16
17 # Augmentasi data
18 x = layers.RandomFlip("horizontal")(inputs)
19 x = layers.RandomZoom(0.2)(x)
20
21 x = base_model(x, training=False)
22
23 # Classifier head
24 x = layers.GlobalAveragePooling2D()(x)
25 x = layers.Dropout(0.5)(x)
26 x = layers.Dense(1024, activation='relu')(x)
27 outputs = layers.Dense(num_classes, activation='↵
    softmax')(x)
28
29 model = tf.keras.Model(inputs, outputs)
30
31 # Kompilasi model
32 model.compile(
33     optimizer=tf.keras.optimizers.Adam(learning_rate),
34     loss='categorical_crossentropy',
35     metrics=[
36         'accuracy',
37         'precision',
38         'recall',
39         tf.keras.metrics.F1Score(average='weighted')
40     ]
41 )
42
43 return model, base_model

```

Kode 4.3: Implementasi Model CNN (ResNet, DenseNet, EfficientNet)

Arsitektur model dirancang dengan menyisipkan lapisan augmentasi data secara langsung sebelum masuk ke *layer base model*. Citra input berukuran 256×256 diproses melalui *layer* RandomFlip horizontal dan RandomZoom 10% untuk meningkatkan variasi data

latih dan mencegah *overfitting*. Model dasar (*base model*) yang digunakan adalah ResNet50, DenseNet121, dan EfficientNetB0 yang telah dilatih dengan dataset ImageNet. *Weight* dari *base model* dibekukan pada tahap *training* awal. Fitur dari *base model* kemudian melewati *layer* GlobalAveragePooling2D dan Dropout. Klasifikasi dilakukan pada *output layer* Dense dengan aktivasi softmax.

B. Implementasi Model Transformer

Implementasi model Transformer menggunakan *library* Hugging Face dan PyTorch. Model *pretrained* yang digunakan adalah ViT dan SwinV2 Transformer. Berbeda dengan CNN, pemrosesan data dilakukan sebelum masuk ke model menggunakan *library* torchvision dan AutoImageProcessor. Implementasi dapat dilihat pada Kode 4.4.

```
1 # 1. Pipeline Augmentasi & Preprocessing
2 augment = transforms.Compose([
3     transforms.RandomHorizontalFlip(p=0.5),
4     transforms.ColorJitter(brightness=0.2, contrast=0.2),
5     transforms.RandomResizedCrop(size=256, scale=(0.8, ←
6         1.0))
7 ])
8 def preprocess_train(examples, image_processor):
9     # Terapkan augmentasi dan konversi ke pixel_values
10    images = [augment(image.convert("RGB")) for image in ←
11        examples['image']]
12    examples['pixel_values'] = image_processor(images, ←
13        return_tensors="pt")['pixel_values']
14    return examples
15
16 # 2. Inisialisasi Model & Trainer
17 model = AutoModelForImageClassification.from_pretrained(←
18     (
19         "microsoft/swin-tiny-patch4-window7-224",
20         num_labels=4,
21         ignore_mismatched_sizes=True # Mengganti head ←
22         klasifikasi
23     )
24 )
25 training_args = TrainingArguments(
26     output_dir="./results",
27     num_train_epochs=30,
28     learning_rate=1e-4,
29     metric_for_best_model="accuracy",
30     load_best_model_at_end=True,
```

```

27     weight_decay=0.01
28 )
29
30 trainer = Trainer(
31     model=model,
32     args=training_args,
33     train_dataset=train_dataset,
34     eval_dataset=eval_dataset,
35     compute_metrics=compute_metrics,
36     callbacks=[EarlyStoppingCallback(↵
37         early_stopping_patience=5)]

```

Kode 4.4: Implementasi Model Transformer

Tahap praproses menerapkan augmentasi seperti `RandomHorizontalFlip`, `ColorJitter`, dan `RandomResizedCrop`. Citra hasil augmentasi kemudian dikonversi menjadi format *patch tensor* sebagai input untuk SwinV2 Transformer dan ViT. Model diinisialisasi menggunakan `AutoModelForImageClassification` dengan konfigurasi layer akhir (*classification head*) dari 1000 kelas menjadi 4 kelas target. Proses pelatihan diatur oleh fungsi `Trainer` yang menangani optimasi *weight*, evaluasi metrik (Akurasi, Presisi, *Recall*, dan *F1-Score*), serta mekanisme Early Stopping untuk menghentikan pelatihan jika validasi tidak membaik.

4.2.3 Implementasi Modul Koreksi Citra

Implementasi modul koreksi bertujuan untuk membangun sistem restorasi citra yang dapat mengoreksi *motion artifact* dan menghasilkan kembali citra MRI yang bersih. Implementasi modul menggunakan *Generative Adversarial Network* (GAN) dengan arsitektur Pix2Pix yang dirancang khusus untuk tugas *image-to-image translation*. Arsitektur ini terdiri dari *Generator* U-Net dan *Discriminator* PatchGAN. Implementasi ini dilakukan menggunakan *library* TensorFlow dan Keras.

A. Arsitektur Generator

Komponen Generator pada Pix2Pix bertugas menerima citra dengan artefak dan menghasilkan citra sintetis yang bersih. Arsitektur yang digunakan adalah U-Net yang dimodifikasi. Struktur ini terdiri dari dua bagian utama:

1. **Encoder (Downsampling)**: Serangkaian lapisan konvolusi yang secara bertahap mengurangi resolusi spasial citra, semisal dari 256×256 menjadi 1×1 untuk mengekstraksi fitur konteks tingkat tinggi.
2. **Decoder (Upsampling)**: Serangkaian lapisan konvolusi transposisi (*Transpose Convolution*) yang mengembalikan resolusi citra ke ukuran aslinya.

Implementasi *Generator* ditunjukkan pada Kode 4.5.

```

1 def Generator():
2     inputs = tf.keras.layers.Input(shape=[256, 256, 3])
3     down_stack = [
4         downsample(64, 4, apply_batchnorm=False),
5         downsample(128, 4),
6         downsample(256, 4),
7         downsample(512, 4),
8         downsample(512, 4),
9         downsample(512, 4),
10        downsample(512, 4),
11        downsample(512, 4),
12    ]
13
14    up_stack = [
15        upsample(512, 4, apply_dropout=True),
16        upsample(512, 4, apply_dropout=True),
17        upsample(512, 4, apply_dropout=True),
18        upsample(512, 4),
19        upsample(256, 4),
20        upsample(128, 4),
21        upsample(64, 4),
22    ]
23
24    initializer = tf.random_normal_initializer(0., 0.02)
25    last = tf.keras.layers.Conv2DTranspose(3, 4, strides←
        =2, padding='same', kernel_initializer=←
        initializer, activation='tanh')
26    x = inputs
27
28    skips = []
29    for down in down_stack:
30        x = down(x)
31        skips.append(x)
32
33    skips = reversed(skips[:-1])
34
35    for up, skip in zip(up_stack, skips):

```

```

36     x = up(x)
37     x = tf.keras.layers.Concatenate()([x, skip])
38
39     x = last(x)
40     return tf.keras.Model(inputs=inputs, outputs=x)

```

Kode 4.5: Implementasi Generator U-Net

Fitur kunci dari implementasi ini adalah penggunaan *skip connections*. Lapisan ini menghubungkan output dari lapisan *encoder* langsung ke lapisan *decoder* yang bersesuaian, misalnya lapisan pertama encoder ke lapisan terakhir decoder. Mekanisme ini memungkinkan informasi detail spasial frekuensi rendah seperti tepi jaringan otak dan pembuluh darah untuk melewati *bottleneck* dan dipulihkan dengan akurat di *output* untuk mencegah hasil yang buram.

B. Arsitektur *Discriminator*

Komponen *Discriminator* bertugas membedakan citra bersih (*ground truth*) dengan citra hasil rekonstruksi *Generator*. Implementasi ini menggunakan arsitektur PatchGAN yang dapat dilihat pada Kode 4.6.

```

1 def Discriminator():
2     # Input 1: Citra Artefak (Kondisi)
3     inp = tf.keras.layers.Input(shape=[256, 256, 3], name←
        = 'input_image')
4
5     # Input 2: Citra Target (Bersih atau Hasil Generator)
6     tar = tf.keras.layers.Input(shape=[256, 256, 3], name←
        = 'target_image')
7
8     # Gabungkan input (Conditional GAN)
9     x = tf.keras.layers.concatenate([inp, tar]) # (bs, ←
        256, 256, 6)
10
11     # Downsampling Layers (Ekstraksi Fitur)
12     down1 = downsample(64, 4, False)(x)
13     down2 = downsample(128, 4)(down1)
14     down3 = downsample(256, 4)(down2)
15
16     # Lapisan Konvolusi dan Zero Padding
17     zero_pad1 = tf.keras.layers.ZeroPadding2D()(down3)
18     conv = tf.keras.layers.Conv2D(512, 4, strides=1, ←
        kernel_initializer=initializer, use_bias=False)(←
        zero_pad1)

```



```

19  batchnorm1 = tf.keras.layers.BatchNormalization()(↵
    conv)
20  leaky_relu = tf.keras.layers.LeakyReLU()(batchnorm1)
21  zero_pad2 = tf.keras.layers.ZeroPadding2D()(↵
    leaky_relu)
22
23  # Output Layer: Matriks Validitas (Patch Map)
24  last = tf.keras.layers.Conv2D(1, 4, strides=1, ↵
    kernel_initializer=initializer)(zero_pad2) # (bs,↵
    30, 30, 1)
25
26  return tf.keras.Model(inputs=[inp, tar], outputs=last↵
    )

```

Kode 4.6: Implementasi *Discriminator* PatchGAN

PatchGAN membagi citra menjadi *patch-patch* kecil, misalnya 70×70 piksel dan menilai keaslian setiap *patch* secara independen. *Output* akhirnya adalah matriks 30×30 nilai validitas. Pendekatan ini memakai *Generator* untuk menghasilkan detail tekstur frekuensi tinggi yang tajam dan realistis di seluruh bagian gambar, tidak hanya secara global.

C. Mekanisme Pelatihan

Mekanisme pelatihan Pix2Pix melibatkan proses optimasi dua jaringan (*Generator* dan *Discriminator*) secara simultan melalui mekanisme permainan *min-max*. Proses ini mencakup definisi fungsi objektif (loss function) dan implementasi langkah pelatihan (training step).

Pelatihan Pix2Pix menggunakan fungsi *loss* gabungan untuk mengoptimalkan *Generator* agar menghasilkan citra yang realistis sekaligus akurat secara struktural. Berikut adalah fungsi *loss* yang digunakan:

1. **Adversarial Loss (GAN Loss):** Menggunakan *Binary Cross-Entropy* untuk menilai seberapa baik *Generator* dapat mengelabui *Discriminator* agar percaya bahwa citra hasil rekonstruksi adalah asli.
2. **L1 Loss (Reconstruction Loss):** Menghitung *Mean Absolute Error* antara piksel citra hasil rekonstruksi dan citra target untuk memastikan warna dan struktur citra hasil sesuai dengan aslinya.

Berikut adalah implementasi dari fungsi *loss*.

```

1  def generator_loss(disc_generated_output, gen_output, ↵
    target):
2  # 1. Adversarial Loss: Generator mencoba menipu ↵
    Discriminator (Target = 1)

```

```

3 gan_loss = loss_object(tf.ones_like(↵
    disc_generated_output), disc_generated_output)
4
5 # 2. L1 Loss: Mengukur perbedaan piksel absolut dengan ↵
    ground truth
6 l1_loss = tf.reduce_mean(tf.abs(target - gen_output))
7
8 # Total Loss dengan pembobotan LAMBDA (100)
9 total_gen_loss = gan_loss + (LAMBDA * l1_loss)
10
11 return total_gen_loss, gan_loss, l1_loss

```

Kode 4.7: Implementasi Fungsi *Loss Generator*

Total *loss* untuk *Generator* adalah total dari kedua *loss* tersebut, dengan bobot $\lambda = 100$ diberikan pada *L1 Loss* untuk memprioritaskan akurasi struktur.

Langkah pelatihan diimplementasikan pada Kode 4.8.

```

1 @tf.function
2 def train_step(input_image, target, epoch):
3     with tf.GradientTape() as gen_tape, tf.GradientTape() ↵
        as disc_tape:
4         # 1. Generator menghasilkan output
5         gen_output = generator(input_image, training=True)
6
7         # 2. Discriminator mengevaluasi input
8         disc_real_output = discriminator([input_image, target↵
            ], training=True)
9         disc_generated_output = discriminator([input_image, ↵
            gen_output], training=True)
10
11        # 3. Hitung Loss
12        gen_total_loss, _, _ = generator_loss(↵
            disc_generated_output, gen_output, target)
13        disc_loss = discriminator_loss(disc_real_output, ↵
            disc_generated_output)
14
15        # 4. Hitung Gradien
16        generator_gradients = gen_tape.gradient(↵
            gen_total_loss, generator.trainable_variables)
17        discriminator_gradients = disc_tape.gradient(↵
            disc_loss, discriminator.trainable_variables)
18
19        # 5. Update Bobot (Backpropagation)
20        generator_optimizer.apply_gradients(zip(↵
            generator_gradients, generator.trainable_variables↵

```

```

    ))
21     discriminator_optimizer.apply_gradients(zip(←
        discriminator_gradients, discriminator.train
22
23     return gen_total_loss, disc_loss

```

Kode 4.8: Implementasi *Train Step* GAN

Fungsi *train_step* dieksekusi pada setiap *batch* data. Fungsi ini menggunakan `tf.GradientTape` untuk merekam operasi dan menghitung gradien secara otomatis. Dalam satu langkah, *Generator* membuat citra rekonstruksi dari *input*, kemudian *Discriminator* menilai citra asli dengan citra hasil rekonstruksi sekaligus menghitung *loss* untuk kedua model. Terakhir, gradien diterapkan untuk memperbarui *weight* dari *Generator* dan *Discriminator* secara independen menggunakan *Adam Optimizer*.

Halaman ini sengaja dikosongkan

BAB V

PENGUJIAN DAN EVALUASI

Bab ini membahas skenario pengujian yang dilakukan untuk memvalidasi kinerja sistem serta hasil evaluasi dari modul klasifikasi dan modul koreksi. Pengujian bertujuan untuk memastikan bahwa model yang dibangun mampu mengenali jenis artefak dengan akurat dan memperbaiki citra yang rusak secara efektif.

5.1 Skenario Pengujian


Skenario pengujian dirancang untuk mengukur kinerja model dalam lingkungan yang terkontrol namun representatif terhadap masalah yang dihadapi. Pengujian dilakukan secara terpisah untuk modul klasifikasi dan modul koreksi.

5.1.1 Lingkungan Pengujian

Seluruh proses pelatihan dan pengujian dilakukan menggunakan platform Kaggle Notebook. Lingkungan ini menyediakan spesifikasi perangkat keras berupa satu GPU NVIDIA Tesla P100 dan RAM sebesar 32 GB yang memadai untuk komputasi *deep learning*. Perangkat lunak utama yang digunakan adalah bahasa pemrograman Python 3.10 dengan dukungan *library* Tensorflow, Pytorch, Transformers, Pandas, NumPy, dan Matplotlib.

5.1.2 Skenario Pengujian Modul Klasifikasi

Pengujian modul klasifikasi bertujuan membandingkan performa antara arsitektur CNN dan Transformer. Dataset yang digunakan terdiri dari 4 jenis kelas (*clean*, *rotation artifact*, *vertical artifact*, *horizontal artifact*) yang diilustrasikan pada Gambar 5.1. Dalam pelaksanaannya, dataset dibagi menjadi data latih (*training set*) yang digunakan untuk melatih bobot model dan data uji (*test set*) yang digunakan sebagai data validasi untuk memantau metrik performa seperti *validation loss* dan akurasi pada setiap epoch. Data uji juga digunakan sebagai acuan dalam penerapan mekanisme *early stopping* untuk mencegah terjadinya *overfitting*.



Gambar 5.1: Kelas Klasifikasi Artefak pada Dataset

Konfigurasi *hyperparameter* ditetapkan secara seragam pada aspek-aspek umum untuk memastikan perbandingan yang adil antara model CNN (ResNet50, DenseNet121, EfficientNetB0) dan Transformer (ViT, Swin Transformer). Meskipun demikian, penyesuaian khusus tetap dilakukan pada komponen *optimizer* dan regularisasi agar kinerja masing-masing arsitektur dapat mencapai titik optimal. Rincian lengkap mengenai konfigurasi tersebut disajikan pada Tabel 5.1

Tabel 5.1: Konfigurasi *Hyperparameter* Model Klasifikasi

Parameter	Konfigurasi CNN	Konfigurasi Transformer
<i>Input Size</i>	ResNet & DenseNet: 256×256 , EfficientNet: 224×224	SwinV2: 224×224 , ViT: 256×256
<i>Batch Size</i>	32	32
<i>Optimizer</i>	Adam	AdamW
<i>Learning Rate</i>	<i>Warm Up</i> : $1e - 4$, <i>Fine tune</i> : $7e - 6$	$1e - 4$
Epochs	<i>Warm Up</i> : 10, <i>Fine Tune</i> : 40	20
Regularisasi	<i>Dropout</i> (0.5), <i>Early Stopping</i> (<i>Patience</i> =5)	<i>Weight Decay</i> (0.01), <i>Early Stopping</i> (<i>Patience</i> =5)
Augmentasi	<i>RandomFlip</i> , <i>RandomZoom</i>	<i>RandomFlip</i> , <i>ColorJitter</i> , <i>RandomResizedCrop</i>

Setelah proses pelatihan selesai, kinerja model dievaluasi secara menggunakan empat metrik klasifikasi utama. Akurasi (*Accuracy*) digunakan untuk melihat rasio prediksi yang benar terhadap keseluruhan data. Presisi (*Precision*) dihitung untuk mengukur ketepatan prediksi positif model terhadap data aktual, yang sangat penting untuk meminimalkan *false positive*. *Recall* (sensitivitas) digunakan untuk mengukur kemampuan model

dalam menemukan kembali seluruh informasi yang relevan. Terakhir, F1-Score digunakan sebagai rata-rata harmonik antara presisi dan *recall* untuk memberikan gambaran kinerja yang seimbang pada dataset *multi-class*.

5.1.3 Skenario Pengujian Modul Koreksi

Pengujian modul koreksi difokuskan untuk menilai kemampuan *Generator* dalam arsitektur Pix2Pix GAN untuk merekonstruksi citra bersih dari citra dengan artefak. Model dilatih dengan input citra berukuran 256×256 piksel selama 250 epoch. Proses optimasi menggunakan algoritma Adam dengan parameter momentum $\beta_1 = 0.5$ dan $\beta_2 = 0.999$, serta learning rate konstan sebesar $2e - 4$. Dalam fungsi *loss* gabungan, bobot λ diatur sebesar 100. Nilai ini dipilih untuk memberikan prioritas yang jauh lebih tinggi pada L1 *Loss* (kemiripan piksel absolut) dibandingkan *Adversarial Loss*. Tujuannya adalah memastikan struktur anatomi otak tetap terjaga dan tidak berubah bentuk meskipun teksturnya diperbaiki oleh GAN.

Kualitas citra hasil rekonstruksi kemudian dievaluasi menggunakan dua metrik standar dalam pemrosesan citra medis. Metrik pertama adalah *Peak Signal-to-Noise Ratio* (PSNR) yang mengukur rasio antara nilai maksimum sinyal dan noise dalam satuan desibel (dB); nilai yang lebih tinggi mengindikasikan kualitas rekonstruksi yang lebih baik. Metrik kedua adalah *Structural Similarity Index* (SSIM) yang mengukur kemiripan struktural (luminansi, kontras, dan struktur) antara citra hasil koreksi dengan citra asli (*ground truth*). Nilai SSIM berkisar antara -1 hingga 1. Nilai yang mendekati 1 menunjukkan bahwa struktur citra hasil rekonstruksi sangat identik dengan aslinya.

5.2 Evaluasi Pengujian

Bagian ini memaparkan hasil eksperimen berdasarkan skenario yang telah ditetapkan di atas, mencakup analisis kuantitatif dan kualitatif.


5.2.1 Evaluasi Modul Klasifikasi Artefak

Berdasarkan pelatihan yang dilakukan pada lima model berbeda, diperoleh hasil evaluasi kuantitatif pada data uji. Rangkuman mengenai metrik terbaik yang dicapai oleh masing-masing model ditunjukkan pada Tabel 5.2.

Tabel 5.2: Perbandingan Kinerja Metrik Model Klasifikasi


Model	Akurasi	Presisi	Recall	F1-Score
ResNet50	0.8890	0.9053	0.8890	0.8908
DenseNet121	0.9031	0.9106	0.9031	0.9035
EfficientNetB0	0.8469	0.8586	0.8469	0.8490
ViT	0.8876	0.8923	0.8876	0.8881
SwinV2 Transformer	0.9382	0.9539	0.9537	0.9536

Analisis hasil menunjukkan bahwa model SwinV2 Transformer mencapai kinerja tertinggi secara konsisten di semua metrik dengan akurasi 93.82% dan F1-Score 95.36%. Keunggulan yang signifikan ini disebabkan oleh mekanisme *shifted window attention* yang efektif menangkap konteks lokal maupun global pada citra artefak.



Gambar 5.2: Grafik Akurasi Pelatihan Model CNN

Pada model berbasis CNN, DenseNet menunjukkan kinerja yang paling tinggi dengan akurasi 90.31% mengungguli ResNet (88.90%). Hal ini menunjukkan bahwa *dense connections* pada DenseNet membantu dalam propagasi fitur yang lebih efisien dibandingkan *residual connections* pada ResNet untuk tugas klasifikasi ini. Namun, secara keseluruhan, arsitektur Transformer menunjukkan potensi yang lebih besar dengan SwinV2 Transformer secara signifikan mengungguli model-model lainnya.



Gambar 5.3: *Confusion Matrix* Model Terbaik (SwinV2 Transformer)

Analisis lebih mendalam dilakukan menggunakan *Confusion Matrix* pada model terbaik (Swin Transformer V2) yang ditunjukkan pada Gambar 5.3 untuk memahami karakteristik prediksi model secara spesifik pada tiap kelas. Model Transformer Swin V2 menunjukkan karakteristik prediksi yang sangat kuat dalam membedakan citra bersih dari citra dengan artefak. Namun, terdapat pola misklasifikasi yang spesifik jika ditinjau antar kategori artefak. Kesalahan prediksi paling signifikan terjadi pada diferen-

siasi antara artefak horizontal dengan artefak rotasi, dilanjutkan oleh kesalahan dalam membedakan artefak vertikal dengan artefak rotasi. Selain itu, terdapat pula kecenderungan model salah mengklasifikasikan artefak rotasi sebagai artefak horizontal, dengan frekuensi tertinggi mencapai 8 sampel pada kategori tersebut. Fenomena ini mengindikasikan bahwa pada irisan otak tertentu, distorsi spasial yang dihasilkan oleh gerakan rotasi memiliki kemiripan fitur tekstur dengan pola *ghosting* atau *blurring* linear yang dihasilkan oleh gerakan translasi secara horizontal maupun vertikal. Hal ini menyebabkan batas keputusan model menjadi sedikit samar di antara jenis-jenis gerakan tersebut.


5.2.2 Evaluasi Modul Koreksi Citra

Pengujian modul koreksi dilakukan dengan membandingkan citra ber-artefak dan citra hasil restorasi *Generator* terhadap citra asli untuk melihat seberapa baik kemiripan citra yang dikoreksi dengan citra aslinya jika dibandingkan dengan citra berartefak. Hasil evaluasi dari 200 sampel gambar tes ditunjukkan pada Tabel 5.3.

Tabel 5.3: Perbandingan Kinerja Metrik Model Koreksi GAN

Metrik	Gambar Berartefak	Gambar Koreksi	Perbedaan
PSNR	34.3287 dB	32.8180 dB	-1.5107
SSIM	0.9061	0.9099	+0.0038

Berdasarkan tabel evaluasi kuantitatif, hasil pengujian menunjukkan peningkatan nilai SSIM pada gambar hasil koreksi dibandingkan dengan baseline gambar berartefak. Peningkatan ini mengindikasikan bahwa model GAN berhasil merestorasi integritas struktural dan geometri anatomis citra medis, sehingga *motion artifact* yang mengganggu visualisasi berhasil direduksi. Sebaliknya, nilai PSNR mengalami penurunan setelah dilakukan koreksi. Penurunan ini menunjukkan bahwa meskipun kualitas visual membaik, terdapat deviasi pada intensitas piksel absolut yang kemungkinan disebabkan oleh *micro-texture generation* atau pergeseran piksel minor yang dilakukan oleh generator untuk meningkatkan ketajaman gambar. Hasil ini menegaskan bahwa model lebih berfokus pada kualitas kemiripan struktur gambar dibandingkan dengan kualitas akurasi pada level piksel.



Gambar 5.4: Perbandingan Visual Hasil Koreksi Citra MRI

Secara kualitatif, Gambar 5.4 menunjukkan kemampuan model dalam meningkatkan ketajaman visual citra yang semula kabur akibat artefak *ghosting*. Alih-alih sekadar mencocokkan intensitas piksel, *Generator* berfokus pada rekonstruksi tekstur dan tepi organ agar terlihat realistis. Hasilnya adalah area latar belakang menjadi lebih bersih dan garis-garis anatomis otak terlihat jauh lebih terlihat dibandingkan citra input. Peningkatan kualitas visual ini mengindikasikan bahwa model memprioritaskan pemulihan fitur-fitur penting yang diperlukan untuk interpretasi visual, meskipun secara statistik terdapat penurunan intensitas sinyal absolut.

Halaman ini sengaja dikosongkan

BAB VI

KESIMPULAN DAN SARAN

6.1 Kesimpulan

Berdasarkan seluruh rangkaian kegiatan kerja praktik yang telah dilakukan mulai dari perancangan hingga pengujian sistem fault tolerance untuk mitigasi artefak gerak pada citra MRI otak, dapat ditarik beberapa kesimpulan utama sebagai berikut.

1. Simulasi *motion artifact* yang dilakukan melalui manipulasi domain frekuensi atau k-space dapat menghasilkan dataset pelatihan yang realistis dan mampu meniru kondisi klinis sebenarnya.
2. Penggunaan arsitektur berbasis Transformer memberikan keunggulan yang signifikan dibandingkan model konvensional CNN dengan model SwinV2 Transformer sebagai model terbaik yang mencatatkan akurasi sebesar 93.82 persen dan F1-Score sebesar 95.36 persen.
3. Modul koreksi berbasis Pix2Pix GAN dapat memulihkan integritas struktural dan ketajaman visual citra yang terdegradasi. Evaluasi menunjukkan peningkatan nilai SSIM yang menunjukkan keberhasilan rekonstruksi batas-batas anatomi otak, meskipun diiringi dengan penurunan nilai PSNR sebagai konsekuensi dari karakteristik model generatif yang memprioritaskan kualitas secara persepsi dibandingkan akurasi intensitas piksel absolut.
4. Integrasi antara modul klasifikasi dan modul koreksi membentuk kerangka kerja fault tolerance yang andal untuk memastikan citra yang diteruskan ke tahap analisis selanjutnya memiliki kualitas yang layak untuk diagnosis.

6.2 Saran

Untuk meningkatkan kinerja dan memperluas cakupan sistem ini di masa mendatang, terdapat beberapa langkah strategis yang dapat dikembangkan lebih lanjut.

1. Pengembangan selanjutnya disarankan dapat mencakup jenis artefak medis lainnya yang sering ditemui dalam MRI seperti artefak

aliasing atau *noise* frekuensi tinggi agar sistem memiliki cakupan proteksi yang lebih menyeluruh.

2. Transisi dari pemrosesan irisan dua dimensi menuju pemrosesan volume MRI tiga dimensi secara utuh sangat disarankan guna menjaga konsistensi fitur anatomi antar-irisan yang lebih baik.
3. Validasi menggunakan dataset artefak dari mesin MRI di rumah sakit diperlukan untuk menguji kemampuan generalisasi model terhadap gerakan pasien yang sebenarnya di lingkungan klinis yang lebih dinamis.
4. Pengujian integrasi penuh secara *end-to-end* dengan sistem *image captioning* medis perlu dilakukan untuk mengukur peningkatan kualitas deskripsi klinis yang dihasilkan secara langsung setelah melalui proses koreksi artefak.

DAFTAR PUSTAKA

- [1] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. 12 2015.
- [2] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. 1 2018.
- [3] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. 6 2021.
- [4] Ze Liu, Han Hu, Yutong Lin, Zhuliang Yao, Zhenda Xie, Yixuan Wei, Jia Ning, Yue Cao, Zheng Zhang, Li Dong, Furu Wei, and Baining Guo. Swin transformer v2: Scaling up capacity and resolution. 4 2022.
- [5] Mojtaba Safari, Xiaofeng Yang, Ali Fatemi, and Louis Archambault. Mri motion artifact reduction using a conditional diffusion probabilistic model (mar-cdpm). *Medical Physics*, 51:2598–2610, 4 2024.
- [6] Jin Liu, Yi Pan, Min Li, Ziyue Chen, Lu Tang, Chengqian Lu, and Jianxin Wang. Applications of deep learning to mri images: A survey, 3 2018.
- [7] Ying Zhuge, Andra V. Krauze, Holly Ning, Jason Y. Cheng, Barbara C. Arora, Kevin Camphausen, and Robert W. Miller. Brain tumor segmentation using holistically nested neural networks in mri images. *Medical Physics*, 44:5234–5243, 10 2017.
- [8] Muhammad Assam, Hira Kanwal, Umar Farooq, Said Khalid Shah, Arif Mehmood, and Gyu Sang Choi. An efficient classification of mri brain images. *IEEE Access*, 9:33313–33322, 2021.
- [9] Christian Hedeager Krag, Felix Christoph Müller, Karen Lind Gandrup, Michael Brun Andersen, Jakob Møllenbach Møller, Marie Louise Liu, Anita Rud, Simon Krabbe, Lamaa Al-Farra, Mads Nielsen,

Christina Kruuse, and Mikael Ploug Boesen. Motion artifacts and image quality in stroke mri: associated factors and impact on ai and human diagnostic accuracy. *European Radiology*, 2025.

- [10] Pál Vakli, Béla Weiss, János Szalma, Péter Barsi, István Gyuricza, Péter Kemenczky, Eszter Somogyi, Ádám Nárai, Viktor Gál, Petra Hermann, and Zoltán Vidnyánszky. Automatic brain mri motion artifact detection based on end-to-end deep learning is similarly effective as traditional machine learning trained on image quality metrics. *Medical Image Analysis*, 88, 8 2023.
- [11] Erik Roecher, Lucas Mösch, Jana Zweerings, Frank O. Thiele, Svenja Caspers, Arnim Johannes Gaebler, Patrick Eisner, Pegah Sarkheil, and Klaus Mathiak. Motion artifact detection for t1-weighted brain mr images using convolutional neural networks. *International Journal of Neural Systems*, 34, 10 2024.
- [12] Marina Manso Jimeno, Keerthi Sravan Ravi, Maggie Fung, John Thomas Vaughan, and Sairam Geethanath. Automated detection of motion artifacts in brain mr images using deep learning and explainable artificial intelligence. 2 2024.
- [13] Mohammed A. Al-masni, Seul Lee, Jaekuk Yi, Sewook Kim, Sung Min Gho, Young Hun Choi, and Dong Hyun Kim. Stacked u-nets with self-assisted priors towards robust correction of rigid motion artifact in brain mri. *NeuroImage*, 259, 10 2022.
- [14] K. Sommer, A. Saalbach, T. Brosch, C. Hall, N. M. Cross, and J. B. Andre. Correction of motion artifacts using a multiscale fully convolutional neural network. *American Journal of Neuroradiology*, 41:416–423, 3 2020.
- [15] Masaaki Hori, Akifumi Hagiwara, Masami Goto, Akihiko Wada, and Shigeki Aoki. Low-field magnetic resonance imaging. *Investigative Radiology*, 56:669–679, 11 2021.
- [16] Yongzhen Huo. Magnetic resonance imaging applications and optimization analysis. 2025.
- [17] Krishna S. Nayak, Yongwan Lim, Adrienne E. Campbell-Washburn, and Jennifer Steeden. Real-time magnetic resonance imaging. *Journal of Magnetic Resonance Imaging*, 55:81–99, 1 2022.

- [18] Katharine E. Thomas, Anastasia Fotaki, René M. Botnar, and Vanessa M. Ferreira. Imaging methods: Magnetic resonance imaging. *Circulation: Cardiovascular Imaging*, 16:E014068, 1 2023.
- [19] Junchi Liu, Mehmet Kocak, Mark Supanich, and Jie Deng. Motion artifacts reduction in brain mri by means of a deep residual network with densely connected multi-resolution blocks (drm-dcmb). *Magnetic Resonance Imaging*, 71:69–79, 9 2020.
- [20] Maxim Zaitsev, Julian Maclaren, and Michael Herbst. Motion artifacts in mri: A complex problem with many partial solutions, 10 2015.
- [21] Shang Hua Gao, Ming Ming Cheng, Kai Zhao, Xin Yu Zhang, Ming Hsuan Yang, and Philip Torr. Res2net: A new multi-scale backbone architecture. *IEEE transactions on pattern analysis and machine intelligence*, 43:652–662, 2 2021.
- [22] Wanni Xu, You Lei Fu, and Dongmei Zhu. Resnet and its application to medical image processing: Research progress and challenges. *Computer Methods and Programs in Biomedicine*, 240, 10 2023.
- [23] Adarsh Vulli, Parvathaneni Naga Srinivasu, Madipally Sai Krishna Sashank, Jana Shafi, Jaeyoung Choi, and Muhammad Fazal Ijaz. Fine-tuned densenet-169 for breast cancer metastasis prediction using fastai and 1-cycle policy. *Sensors*, 22, 4 2022.
- [24] Xia Li, Xi Shen, Yongxia Zhou, Xiuhui Wang, and Tie Qiang Li. Classification of breast cancer histopathological images using interleaved densenet with senet (idsnet). *PLoS ONE*, 15, 5 2020.
- [25] Zhiwen Huang, Xingxing Zhu, Mingyue Ding, and Xuming Zhang. Medical image classification using a light-weighted hybrid neural network based on pcnet and densenet. *IEEE Access*, 8:24697–24712, 2020.
- [26] Ana Davila, Jacinto Colan, and Yasuhisa Hasegawa. Comparison of fine-tuning strategies for transfer learning in medical image classification. *Image and Vision Computing*, 146, 6 2024.

- [27] Van Thanh Hoang and Kang Hyun Jo. Practical analysis on architecture of efficientnet. In *International Conference on Human System Interaction, HSI*, volume 2021-July. IEEE Computer Society, 7 2021.
- [28] Hussein Alshaari and Saeed Alqahtani. Deep-efnet: An optimized efficientnetb0 architecture with dual regularization for scalable multi-class brain tumor classification in mri. *IEEE Access*, 13:85682–85697, 2025.
- [29] Tariq Shahzad, Tehseen Mazhar, Sheikh Muhammad Saqib, and Khmaies Ouahada. Transformer-inspired training principles based breast cancer prediction: combining efficientnetb0 and resnet50. *Scientific Reports*, 15, 12 2025.
- [30] Dr. R. G. Suresh Kumar. Deep learning-based diagnosis for skin disease prediction. *International Journal for Research in Applied Science and Engineering Technology*, 13:2705–2715, 5 2025.
- [31] Fahad Shamshad, Salman Khan, Syed Waqas Zamir, Muhammad Harris Khan, Munawar Hayat, Fahad Shahbaz Khan, and Huazhu Fu. Transformers in medical imaging: A survey, 8 2023.
- [32] Yaoli Wang, Yaojun Deng, Yuanjin Zheng, Pratik Chattopadhyay, and Lipo Wang. Vision transformers for image classification: A comparative survey, 1 2025.
- [33] Tahir Hussain, Hayaru Shouno, Abid Hussain, Dostdar Hussain, Muhammad Ismail, Tatheer Hussain Mir, Fang Rong Hsu, Taukir Alam, and Shabnur Anonna Akhy. Effresnet-vit: A fusion-based convolutional and vision transformer model for explainable medical image classification. *IEEE Access*, 13:54040–54068, 2025.
- [34] Hanguang Xiao, Li Li, Qiyuan Liu, Xiuhong Zhu, and Qihang Zhang. Transformers in medical image segmentation: A review, 7 2023.
- [35] Khalid Al-hammuri, Fayeze Gebali, Awos Kanan, and Ilamparithi Thirumarai Chelvan. Vision transformer architecture and applications in digital health: a tutorial and survey, 12 2023.

- [36] Sanad Aburass, Osama Dorgham, Jamil Al Shaqsi, Maha Abu Rumman, and Omar Al-Kadi. Vision transformers in medical imaging: a comprehensive review of advancements and applications across multiple diseases, 12 2025.
- [37] Kerr Fitzgerald, Jorge Bernal, Aymeric Histace, and Bogdan J. Matuszewski. Polyp segmentation with the fcb-swinv2 transformer. *IEEE Access*, 12:38927–38943, 2024.
- [38] Yufan He, Vishwesh Nath, Dong Yang, Yucheng Tang, Andriy Myronenko, and Daguang Xu. Swinunetr-v2: Stronger swin transformers with stagewise convolutions for 3d medical image segmentation. In *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, volume 14223 LNCS, pages 416–426. Springer Science and Business Media Deutschland GmbH, 2023.
- [39] Jie Gui, Zhenan Sun, Yonggang Wen, Dacheng Tao, and Jieping Ye. A review on generative adversarial networks: Algorithms, theory, and applications. *IEEE Transactions on Knowledge and Data Engineering*, 35:3313–3332, 4 2023.
- [40] Tao Zhou, Qi Li, Huiling Lu, Qianru Cheng, and Xiangxiang Zhang. Gan review: Models and medical image fusion applications. *Information Fusion*, 91:134–148, 3 2023.
- [41] Jiwoong J. Jeong, Amara Tariq, Tobiloba Adejumo, Hari Trivedi, Judy W. Gichoya, and Imon Banerjee. Systematic review of generative adversarial networks (gans) for medical image classification and segmentation, 4 2022.
- [42] Ahmed Makhlof, Marina Maayah, Nada Abughanam, and Catagay Catal. The use of generative adversarial networks in medical image augmentation, 12 2023.
- [43] Showrov Islam, Md Tarek Aziz, Hadiur Rahman Nabil, Jamin Rahman Jim, M. F. Mridha, Md Mohsin Kabir, Nobuyoshi Asai, and Jungpil Shin. Generative adversarial networks (gans) in medical imaging: Advancements, applications, and challenges. *IEEE Access*, 12:35728–35753, 2024.

- [44] Manal Alamir and Manal Alghamdi. The role of generative adversarial network in medical image analysis: An in-depth survey. *ACM Computing Surveys*, 55:1–36, 5 2023.
- [45] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, and Alexei A. Efros. Image-to-image translation with conditional adversarial networks. 11 2018.
- [46] Hazem Abdelmotaal, Ahmed A. Abdou, Ahmed F. Omar, Dalia Mohamed El-Sebaity, and Khaled Abdelazeem. Pix2pix conditional generative adversarial networks for scheimpflug camera color-coded corneal tomography image generation. *Translational Vision Science and Technology*, 10, 6 2021.
- [47] Ryo Toda, Atsushi Teramoto, Masashi Kondo, Kazuyoshi Imaizumi, Kuniaki Saito, and Hiroshi Fujita. Lung cancer ct image generation from a free-form sketch using style-based pix2pix for data augmentation. *Scientific Reports*, 12, 12 2022.
- [48] Jude Chukwura Obi. A comparative study of several classification metrics and their performances on data. *World Journal of Advanced Engineering Technology and Sciences*, 8:308–314, 2 2023.
- [49] Mohammad R. Salmanpour, Morteza Alizadeh, Ghazal Mousavi, Saba Sadeghi, Sajad Amiri, Mehrdad Oveisi, Arman Rahmim, and Ilker Hacihaliloglu. Machine learning evaluation metric discrepancies across programming languages and their components in medical imaging domains: Need for standardization. *IEEE Access*, 13:47217–47229, 2025.
- [50] Shreyan Simhadri, Manoj Ponnamp, Ramasani Rajitha, and R. Balamurugan. Enhanced multi-class model evaluation: Analyzing bert, gpt-2, and llama with precision, recall, and f1-score metrics. In *2025 4th International Conference on Innovative Mechanisms for Industry Applications (ICIMIA)*, pages 984–989. IEEE, 9 2025.
- [51] Umme Sara, Morium Akter, and Mohammad Shorif Uddin. Image quality assessment through fsim, ssim, mse and psnr—a comparative study. *Journal of Computer and Communications*, 07:8–18, 2019.

- [52] Yucheng Li, Yang Zhang, Deyu Jia, Song Gao, and Muqun Zhang. Noise impact analysis in computer-generated holography based on dual metrics evaluation via peak signal-to-noise ratio and structural similarity index measure. *Applied Sciences (Switzerland)*, 15, 6 2025.
- [53] Jiayuan Peng, Chengyu Shi, Eric Laugeman, Weigang Hu, Zhen Zhang, Sasa Mutic, and Bin Cai. Implementation of the structural similarity (ssim) index as a quantitative evaluation tool for dose distribution error detection. *Medical Physics*, 47:1907–1919, 4 2020.
- [54] Lili Lin, Hong Chen, Ercan Engin Kuruoglu, and Wenhui Zhou. Robust structural similarity index measure for images with non-gaussian distortions. *Pattern Recognition Letters*, 163:10–16, 11 2022.
- [55] Himanshu Yadav. Structural similarity index measure based signature verification using python. *International Journal for Research in Applied Science and Engineering Technology*, 13:4086–4088, 5 2025.

Halaman ini sengaja dikosongkan

BIODATA PENULIS

Nama : Alief Gilang Permana Putra
Tempat, Tanggal Lahir : Gresik, 01 Desember 2004
Jenis Kelamin : Laki-laki
Telepon : 087815865064
Email : 5025221193@student.its.ac.id

AKADEMIS

Kuliah : Departemen Teknik Informatika –
FTEIC, ITS
Angkatan : 2022
Semester : 7 (Tujuh)